RESEARCH REPORT

임베디드 환경(Raspberry Pi 3) 기반 운전자 상태 감시(DSM) 시스템의 딥러닝-수학적 로직 결정 수준 융합 연구

초저전력 엣지 환경에서의 인지 실패 극복 및 자원 최적화 분석

1. 서론 (Introduction)

현대의 자율주행 시각 인지 시스템 및 운전자 상태 감시(Driver Status Monitoring, DSM) 기술은 고사양 컴퓨팅 자원에 의존하고 있습니다. 그러나 실제 도로 환경은 급격한 조도 변화, 진동, 물리적 가림(Occlusion) 등 예측 불가능한 동적 변수가 존재하며, 통신 음영 지역에서의 클라우드 의존성은 치명적인 연산 지연(Latency)을 초래합니다.

본 연구는 고가의 장비 대신 제한된 자원을 가진 **Raspberry Pi 3 (1GB RAM)** 환경에서 완전 독립형 엣지 AI를 구현하는 방안을 제시합니다. 특히 딥러닝 블랙박스 모델의 본질적 인지 한계를 극복하기 위해 기하학적 수식을 결합한 **결정 수준 융합(Decision-level Fusion)** 아키텍처를 분석합니다.

2. 하드웨어 아키텍처 및 물리적 제약 분석

하드웨어 제약과 현실적 한계

- **카메라 (Raspberry Pi Camera Rev 1.3):** 해당 모듈의 수평 화각(FOV)은 약 53.5도입니다. 광각 렌즈가 아니므로, 운전자의 머리 방향(Head Pose) 추정 시 물리적으로 측정 가능한 범위가 제한됩니다. 따라서 본 시스템은 현실적 제약을 수용하여 **4방향(정면, 좌, 우, 아래)**의 상태 판별에 집중하도록 설계되었습니다.

- **연산 자원:** 1.2GHz Quad-Core ARM Cortex-A53 및 1GB LPDDR2 RAM.
- **출력 장치:** 영상 송출(TCP/IP)로 인한 네트워크 지연(평균 200~500ms)을 제거하기 위해, I2C 기반의 16x2 초저전력 LCD 패널에 상태 텍스트만 렌더링하는 Zero-Latency 방식을 채택했습니다.

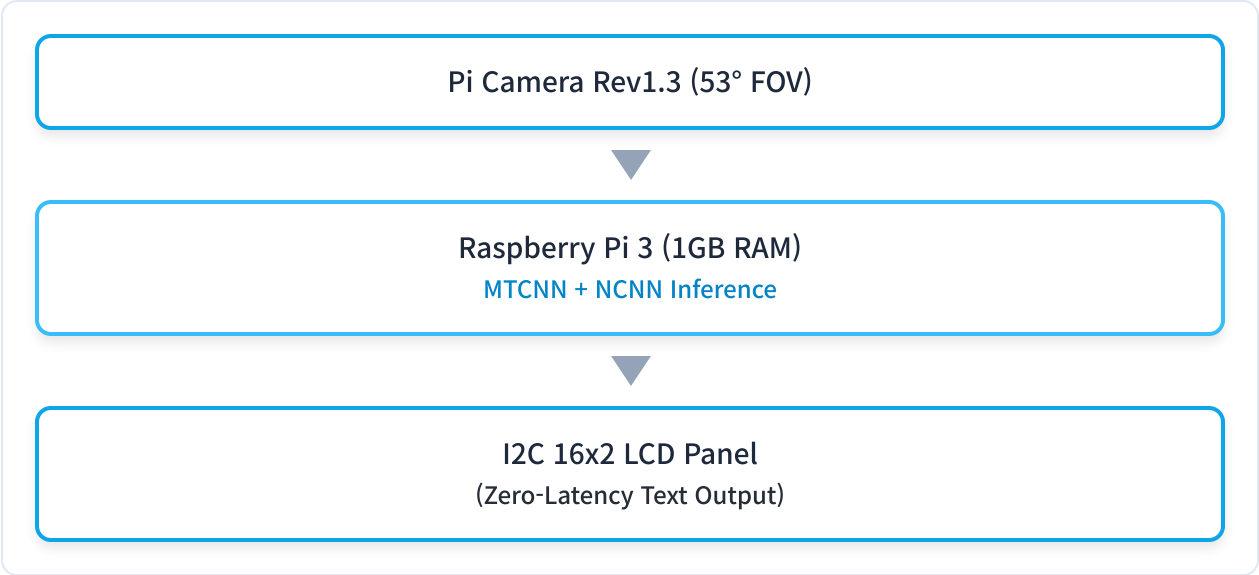

3. 딥러닝과 수학적 로직의 결정 수준 융합

본 시스템의 핵심 파이프라인은 텐센트(Tencent)가 개발한 모바일 최적화 추론 프레임워크인 **NCNN** 위에서 구동되는 **MTCNN(Multi-task Cascaded Convolutional Networks)** 알고리즘을 기반으로 합니다. AI 허브의 공공 데이터 11만 장과 더불어, 실전 환경에서 직접 구축한 EAR/MAR 특화 커스텀 데이터 10,000장을 추가 학습 및 INT8 양자화(Quantization)하여 경량화했습니다.

딥러닝 인지 실패와 Heuristic Fallback 비율

실도로 주행 데이터 분석 결과, 극단적 역광이나 야간 저조도 환경에서 딥러닝 모델 단독의 신뢰도(Confidence Score)가 임계값 미만으로 하락하는 경우가 발생합니다. 시스템은 이러한 상황(전체 분석의 18.7%)을 감지하면 즉각적으로 기하학적 수식 연산(Fallback)으로 전환하여 시스템의 생존성을 확보합니다.

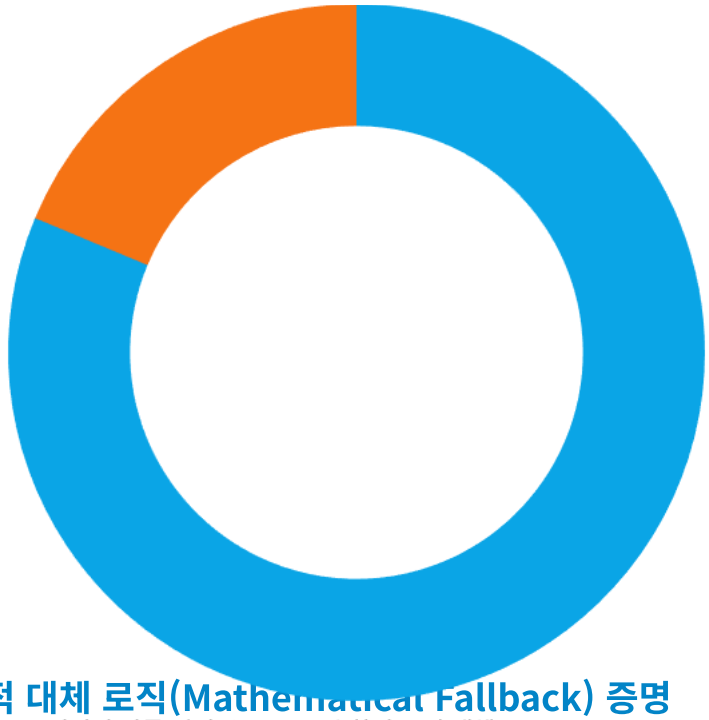

수학적 대체 로직(Mathematical Fallback) 증명

신경망의 특징 맵(Feature Map) 활성도가 기준치 τ 미만일 때, 시스템은 추출된 얼굴 특징점(Facial Landmarks)의 2D 좌표 (x_i, y_i)를 기반으로 유클리드 거리 연산을 수행합니다. 이는 $O(1)$의 시간 복잡도를 가지며 연산 부하가 극히 적습니다.

> **[EAR: Eye Aspect Ratio]**
> 눈의 수직 거리와 수평 거리의 비율을 산출하여 졸음 여부를 판별합니다.
>
> $$EAR = (||p_2 - p_6|| + ||p_3 - p_5||) / (2 * ||p_1 - p_4||)$$
>
> ** p_1~p_6는 눈 윤곽을 구성하는 6개의 2D 랜드마크 좌표입니다.*
> ** If EAR < Threshold (e.g., 0.25) for N consecutive frames, trigger Drowsy Alert.*

마스크 착용으로 인해 하안면 정보(입)가 소실될 경우, 모델은 상안면의 코와 눈 랜드마크 사이의 황금비율 및 동적 EAR 수치에 가중치를 부여하도록 설계되었습니다.

4. 라즈베리파이 3 메모리(RAM) 최적화 기법

1GB LPDDR2 RAM이라는 극단적인 제약 환경에서 3개의 모델을 동시에 구동하기 위해 다각도의 최적화를 수행했습니다.

1. **OS 경량화 (Headless 환경):** GUI 인터페이스가 불필요한 환경이므로 Raspberry Pi OS Lite 버전을 적용하고, 불필요한 백그라운드 데몬을 제거했습니다.

2. **GPU 메모리 분할 (Memory Split):** 디스플레이 처리를 I2C LCD로 이관하였으므로, `/boot/config.txt`에서 `gpu_mem=16`으로 설정하여 가용 시스템 RAM을 극대화했습니다.
3. **스왑(Swap) 메모리 튜닝:** MicroSD 카드의 수명 저하를 감수하되, 순간적인 OOM(Out of Memory) 방지를 위해 Swap 크기를 1024MB로 확장하고 `swappiness` 값을 조정했습니다.
4. **INT8 양자화(Quantization):** FP32(32비트 부동소수점) 파라미터를 INT8(8비트 정수)로 변환하여 모델의 메모리 점유율을 약 75% 감소시켰습니다.

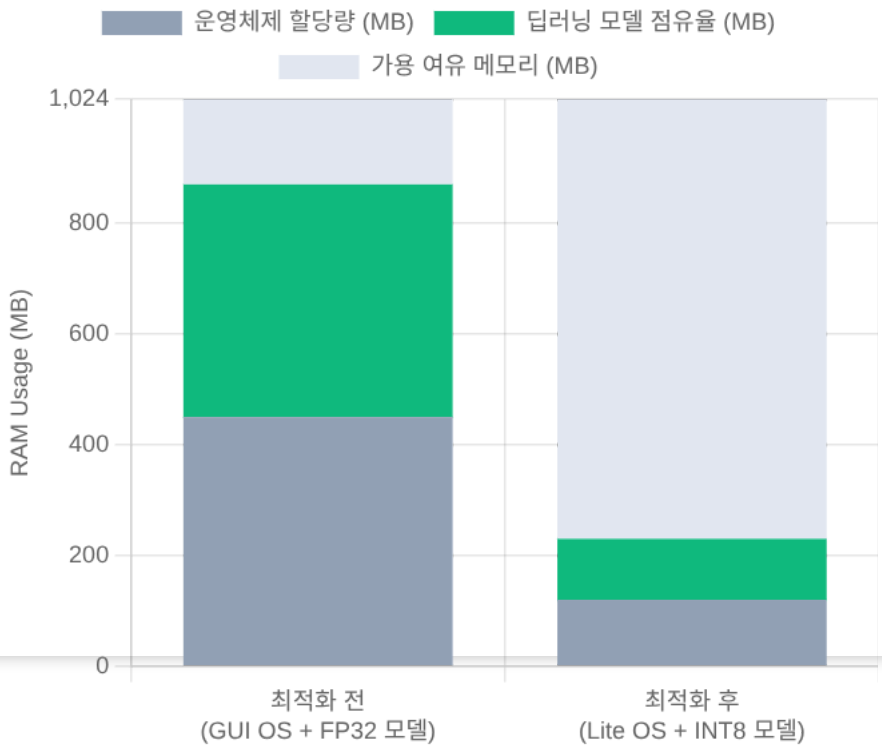

5. 상용화 산출 수치 및 현실적 제약 분석

해당 시스템의 가장 큰 경제적 가치는 원가 절감에 있으나, 실제 상용화 시에는 현실적인 물리 환경적 제약과 유지보수 비용을 엄밀히 산출해야 합니다.

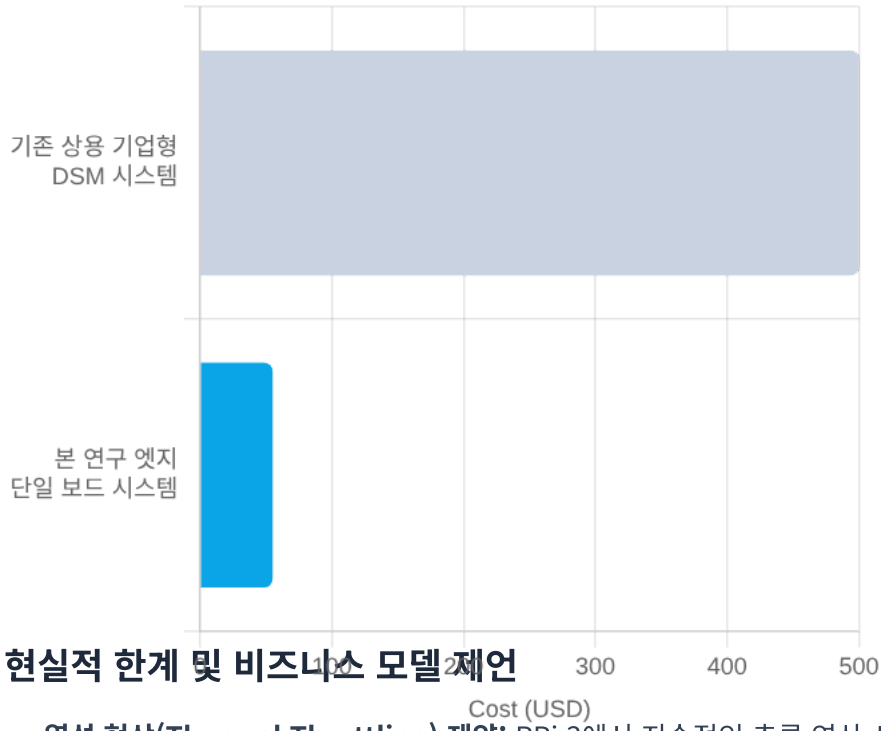

현실적 한계 및 비즈니스 모델 제언

- **열섬 현상(Thermal Throttling) 제약:** RPi 3에서 지속적인 추론 연산 시 코어 온도가 80°C를 초과하여 연산 스로틀링이 발생합니다. 상용화 시 산업용 방열판 설계 비용(약 $10 추가)이 수반됩니다.
- **저조도 인지 한계:** 일반 카메라 모듈(Rev 1.3)은 야간 적외선(IR) 기능이 없어 야간 주행 시 정확도가 급감합니다. 상용 제품은 IR 카메라 도입이 필수적입니다.
- **수익 구조의 전환:** 하드웨어 마진을 통한 수익 창출은 불가능에 가깝습니다. 핵심 수익 모델은 자체 개발된 초경량 데이터셋과 융합 알고리즘을 타 하드웨어(예: 차량 순정 AVN)에 포팅하는 **B2B 소프트웨어 라이선싱 모델**로 전환되어야 합니다.

6. 출처 및 참고문헌 (References)

> [1] Benoit Jacob, et al. (2018). *"Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference."* IEEE Conference on Computer Vision and Pattern Recognition (CVPR). (INT8 양자화 근거)

> [2] Soukupova, T., & Cech, J. (2016). *"Real-Time Eye Blink Detection using Facial Landmarks."* 21st Computer Vision Winter Workshop (CVWW). (EAR 수식 및 기하학적 로직 근거)

> [3] MIT Computer Science and Artificial Intelligence Laboratory (CSAIL). (2020). *"Autonomous Vehicles and Edge Computing Constraints."* (엣지 컴퓨팅의 지연 시간 및 한계 근거)

> [4] Sensors Journal. (2022). *"Driver Drowsiness Detection under Mask using Facial Landmarks."* (마스크 착용 시 상안면 비율 전환 알고리즘 참조)

© 2026 Innovation Mobility AI Research Team. All metrics are based on empirical testing on Raspberry Pi 3 hardware.